Trabajo Final - AAGrafos - 2025
Predicción de Flujos de Carga AC utilizando Redes Neuronales de Grafos

Facundo Gil, Elias Courdin

Introducción

Éste trabajo final está fuertemente ligado a un Proyecto de Fin de Carrera en desarrollo que aborda el problema de Predicción de Flujos de Carga AC para Redes Eléctricas, utilizando modelos basados en Redes Neuronales de Grafos (GNNs) [1].

Presentación del problema

El problema del cálculo eficiente y preciso del flujo de carga en sistemas de potencia ha recibido atención creciente en la última década, impulsado por la necesidad de evaluar numerosos escenarios (expansión, contingencias, incertidumbre renovable) en tiempos de cómputo reducidos. Los enfoques clásicos (p. ej. Newton–Raphson, Gauss–Seidel) mantienen un alto estándar de precisión pero resultan costosos en redes de gran escala, lo que ha motivado la búsqueda de aproximaciones que reduzcan el coste computacional sin sacrificar garantías físicas esenciales.
Recientes trabajos han explorado el uso de técnicas de aprendizaje automático (ML) [2] y, en particular, de graph neural networks (GNNs) [3] para aproximar la solución del flujo de carga AC con tiempos de inferencia considerablemente menores a los obtenidos mediante métodos numéricos tradicionales. Además, las GNNs logran capturar la estructura natural subyacente de la topología de una red eléctrica y sus conexiones.

¿Qué es el flujo de carga?

El flujo de carga constituye un estudio fundamental en el análisis de los sistemas eléctricos de potencia, cuyo objetivo principal es determinar el estado operativo de la red en condiciones de régimen permanente. Mediante este análisis se obtienen las tensiones en las barras, los ángulos de fase, y los flujos de potencia activa y reactiva en las líneas y transformadores, a partir de los datos de generación, demanda y configuración del sistema. El flujo de carga se formula a partir de las ecuaciones nodales que relacionan las inyecciones de potencia con las tensiones del sistema, utilizando la matriz de admitancias nodal $\mathbf{Y}$. Dado que estas ecuaciones son no lineales, su resolución requiere la aplicación de métodos iterativos, siendo los más empleados el método de Newton–Raphson y el método desacoplado rápido. La información obtenida a partir del flujo de carga resulta esencial para la planificación, operación y expansión de los sistemas eléctricos, ya que permite verificar el funcionamiento adecuado del sistema bajo diferentes escenarios de demanda y generación, así como evaluar el cumplimiento de límites de tensión, capacidad de transmisión y condiciones de estabilidad operativa.

Modelado de la Red Eléctrica

En el estudio de flujo de carga, los distintos elementos del sistema eléctrico se representan mediante modelos equivalentes que permiten describir su comportamiento en régimen permanente.

- **Líneas de transmisión (aristas)**: se representan mediante el modelo en circuito π, que incluye la impedancia serie $(R + jX)$ y la susceptancia en derivación distribuida entre ambos extremos.

- **Transformadores**: se modelan a través de su impedancia de cortocircuito y, en caso necesario, mediante relaciones de transformación con tap y ángulo de desfasaje.
- **Generadores**: se representan como fuentes de potencia activa constante con capacidad de regulación de tensión en su barra de conexión, dentro de límites operativos ($P = \text{cte},\ V = \text{cte}$).
- **Cargas**: se consideran como demandas de potencia compleja constante ($P = \text{cte},\ Q = \text{cte}$).
- **Compensadores**: dispositivos conectados en derivación o en serie (como bancos de capacitores, reactores o compensadores síncronos) que permiten modificar el flujo de potencia reactiva y regular el perfil de tensión.
- **Barras (nodos)**: nodos del sistema donde se interconectan los diferentes elementos (generadores, cargas, líneas, transformadores, compensadores, etc.), y que constituyen los puntos de referencia para el cálculo de tensiones y potencias.

  En el problema de flujo de carga, cada barra del sistema se clasifica dentro de los tres tipos principales:

  - **Barra Slack o de referencia**: También llamada barra swing, es la barra que fija el valor de referencia del ángulo de tensión del sistema. Se especifica la magnitud de la tensión $|V|$ y el ángulo θ (comúnmente $\theta = 0°$).
  - **Barras PV (generador)**: En estas barras se especifica la potencia activa generada P y la magnitud de la tensión $|V|$. El ángulo de tensión θ y la potencia reactiva Q se calculan como resultado de la solución del flujo de carga. Estas barras representan unidades generadoras con control de tensión dentro de límites preestablecidos de potencia reactiva.
  - **Barras PQ (carga)**: En estas barras se especifican las potencias activa y reactiva demandadas (P y Q). Las incógnitas a resolver son la magnitud $|V|$ y el ángulo θ de la tensión. Representan a las cargas del sistema, modeladas como demandas de potencia constante.

Ecuaciones del flujo de carga

El análisis de flujo de carga se fundamenta en la representación de la red mediante la *matriz de admitancias nodal* $\mathbf{Y}$. Esta matriz es una construcción algebraica que refleja la estructura topológica y los parámetros eléctricos del sistema.
En general, $\mathbf{Y}$ es una matriz compleja cuadrada de dimensión $N \times N$, donde N es el número de barras (nodos) del sistema. Cada elemento se define como:

$$Y_{ij} = \begin{cases} \displaystyle\sum_{k \in \mathcal{N}(i)} y_{ik} + y_{sh,i}, & \text{si } i = j, \\ -y_{ij}, & \text{si } i \neq j \text{ y existe una conexión directa entre } i \text{ y } j, \\ 0, & \text{si } i \neq j \text{ y no existe conexión.} \end{cases}$$

Donde:

- $y_{ij} = 1/(r_{ij} + jx_{ij})$ es la admitancia serie de la rama que conecta las barras i y j.
- $y_{sh,i}$ es la admitancia en derivación conectada directamente a la barra i (proveniente de elementos shunt o de la mitad de la susceptancia de carga de las líneas).
- $\mathcal{N}(i)$ representa el conjunto de barras conectadas directamente a la barra i.

$$\mathbf{Y} = \begin{bmatrix} Y_{11} & Y_{12} & \cdots & Y_{1N} \\ Y_{21} & Y_{22} & \cdots & Y_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ Y_{N1} & Y_{N2} & \cdots & Y_{NN} \end{bmatrix} = \begin{bmatrix} G_{11} + jB_{11} & G_{12} + jB_{12} & \cdots & G_{1N} + jB_{1N} \\ G_{21} + jB_{21} & G_{22} + jB_{22} & \cdots & G_{2N} + jB_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ G_{N1} + jB_{N1} & G_{N2} + jB_{N2} & \cdots & G_{NN} + jB_{NN} \end{bmatrix}.$$

Con esta formulación, se cumple la relación fundamental:

$$I = \mathbf{Y}V, \tag{1}$$

donde I es el vector de corrientes inyectadas y V el vector de tensiones nodales.
A partir de aquí, se definen las potencias inyectadas en la barra i como:

$$S_i = P_i + jQ_i = V_i I_i^* = V_i \left(\sum_{j=1}^{N} Y_{ij} V_j \right)^* , \tag{2}$$

y, separando en sus componentes real e imaginaria, se obtienen las ecuaciones no lineales de flujo de carga:

$$P_i = \sum_{j=1}^{N} |V_i||V_j| \left(G_{ij} \cos\theta_{ij} + B_{ij} \sin\theta_{ij} \right) , \tag{3}$$

$$Q_i = \sum_{j=1}^{N} |V_i||V_j| \left(G_{ij} \sin\theta_{ij} - B_{ij} \cos\theta_{ij} \right) , \tag{4}$$

donde $G_{ij} = Re(Y_{ij})$, $B_{ij} = Im(Y_{ij})$ y $\theta_{ij} = \theta_i - \theta_j$ es la diferencia angular entre las tensiones de las barras i y j.
Estas ecuaciones constituyen el núcleo del problema de flujo de carga y, debido a su naturaleza no lineal, requieren ser resueltas mediante algoritmos iterativos.

Creación de datasets

Para la creación de los datasets se puede utilizar la plataforma **SimSEE** [4] (Simulador del Sistema Eléctrico de Energía), desarrollada en Uruguay por el Laboratorio de Energía de la Facultad de Ingeniería (Udelar) junto con UTE y otros organismos. Esta herramienta permite simular el comportamiento del sistema eléctrico mediante modelos estocásticos que representan tanto la variabilidad de los recursos renovables como la incertidumbre de la demanda. A partir de estos modelos **SimSee** permite generar diferentes escenarios operativos para una misma red.

Red IEEE39

La red utilizada para la creación del dataset es la red IEEE39, compuesta por 39 buses como se observa en la figura 1. De estos, 10 buses tienen generadores conectados y se modelan como nodos PV, mientras que el resto de los buses corresponden a nodos PQ, a expceción del nodo slack.
La topología de la red se considera fija y conocida, y representa una aproximación estándar de un sistema de transmisión realista. Sobre esta estructura se definen los distintos escenarios operativos generados por SimSEE.

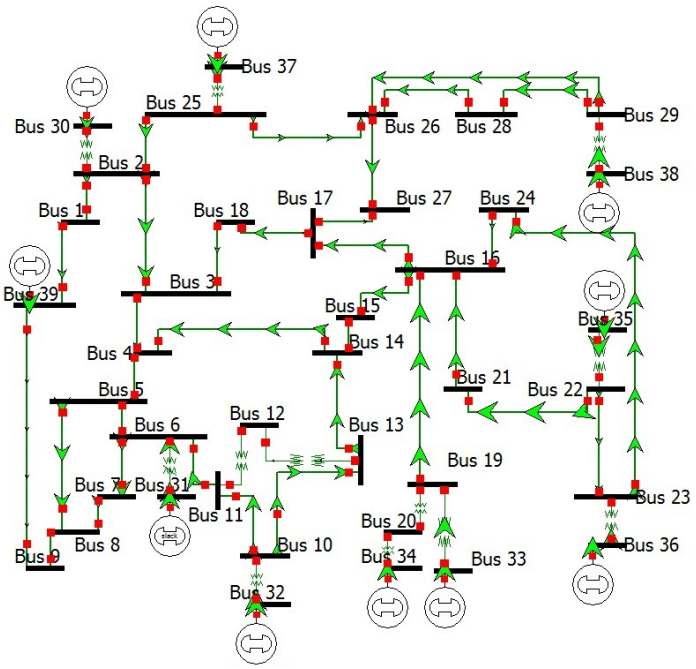

Figura 1: Red IEEE39

Generación de muestras

La generación de las muestras se basa en la construcción de distintos escenarios operativos a partir de perfiles temporales de demanda y generación representativos del sistema eléctrico uruguayo.
Se considera la demanda anual agregada de Uruguay, la cual se utiliza como referencia para definir el nivel total de consumo del sistema en cada instante. Esta demanda total se distribuye de forma proporcional entre los buses de carga de la red IEEE39, de acuerdo con factores fijos asociados a cada nodo. De esta manera, se preserva la estructura relativa de la demanda en la red.
La generación eléctrica se modela a partir de la contribución de tres fuentes principales: eólica, solar y térmica. Se cálcula la potencia necesaria para abastecer toda la demanda y a partir de las tres fuentes se abastece la demanda. Los nodos generadores se seleccionan como un solo tipo de generación, teniendo en cuenta similitudes con la red eléctrica uruguaya para esta elección.

Resolución del problema para cada escenario

Para cada escenario de generación y demanda (para la topología fija y hasta una contingencia) se resuelve el problema de flujo de carga mediante el uso de la herramienta PSSE [5], que permite para un escenario de demanda y generación resolver el flujo de carga para una topología. La herramienta utiliza métodos númericos para la resolución, en particular se resuelve mediante el uso del algoritmo Newton-Raphson. Asi se obtienen las etiquetas para el conjunto de datos, que corresponden a los valores de $\mathbf{V}$ (voltaje) y θ (desfasaje del voltaje con respecto al nodo slack) para cada nodo.

Modelado del Problema

Los datos obtenidos se modelan como un grafo, donde cada dato es un grafo no dirigido de 39 nodos y 46 aristas. Para cada nodo se especifican 6 atributos. Los tres primeros corresponden a la potencia generada, la potencia demandada, y la reactiva demandada según el caso (o escenario). Los otros tres atributos corresponden a un one-hot encoding indicando el tipo de nodo (Slack, PV, PQ).
Cada arista tiene su valor complejo de impedancia, señalado como dos valores escalares (G,B) correspondientes a la parte real e imaginaria de la impedancia $\mathbf{Y}$. Es decir, todos los grafos del dataset son como el grafo de la figura 2, variando los atributos de los nodos según el caso.

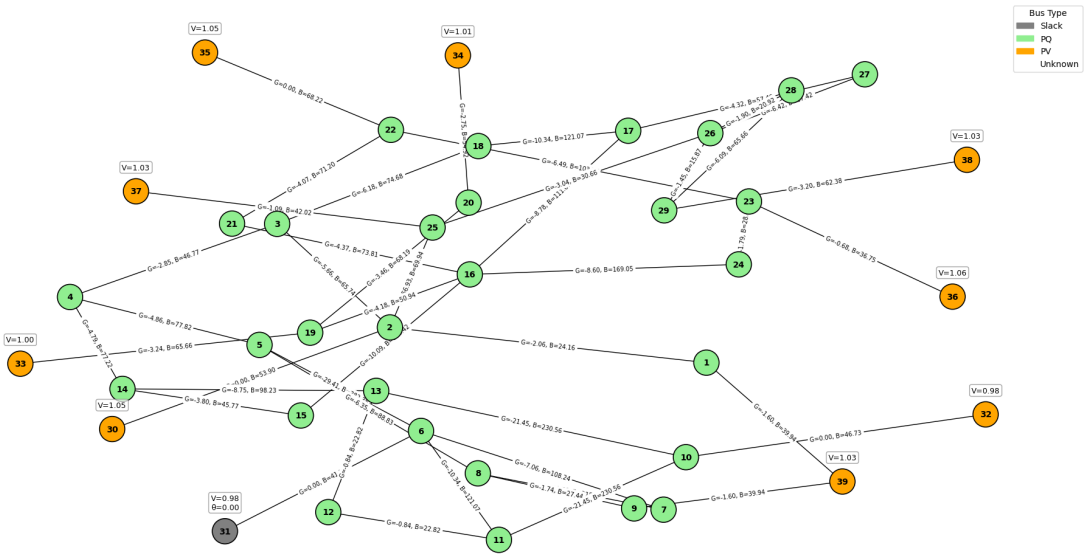

Figura 2: Grafo de la red IEEE39

Función de Pérdida (Loss)

Para entrenar un modelo de aprendizaje automático que pueda predecir las tensiones y desfasajes en cada nodo a partir de las potencias de entrada y las conexiones entre los nodos surgen dos posibles enfoques.

Por un lado, al tener las etiquetas en el dataset, se podría adoptar un enfoque supervisado en el que se enseña al modelo a predecir las etiquetas, sin embargo no resulta de tanto interés este enfoque, ya que se pretende que el modelo sea capaz de capturar patrones relacionados estrictamente con los aspectos físicos del problema. Además, en datasets más grandes existen casos donde los métodos numéricos no convergen a una solución, de modo que habrá datos con etiquetas no válidas. Ésto motiva la búsqueda de un enfoque no supervisado que pueda aprovechar las ecuaciones físicas que rigen el problema de fondo.

El enfoque que se adopta para esta trabajo es entonces no supervisado. Esta estrategia consiste en diseñar una loss basada en minimizar el error en el cumplimiento de las ecuaciones físicas propias del problema de flujo de carga AC. Observando las ecuaciones 3 y 4, podemos construír estimaciones de las potencias de entrada en los nodos a partir de las estimaciones (predicciones) del modulo y fase de los voltajes provenientes de un modelo de GNN, y comparar el error entre las potencias especificadas en el dataset y las calculadas a partir de las predicciones.

Sin embargo, el cumplimiento de las ecuaciones de flujo de carga solo tiene sentido para los nodos PQ, y parcialmente para los nodos PV. Esto se debe a que los nodos PQ son los que deben ajsutar su valor complejo de voltaje al cumplimiento de las ecuaciones físicas, y los nodos PV deben fijar la magnitud de su voltaje al objetivo prefijado y ajustar únicamente su desfasaje al cumplimiento de las ecuaciones físicas. Por otro lado, los nodos *Slack* solamente deben ajustar a sus valores objetivos. Los valores objetivos utilizados para este trabajo se observan en el grafo de la figura 2. A continuación se define la función de Loss utilizada para el entrenamiento, donde se recuerda que las predicciones del modelo son los valores V y θ para cada nodo $i = 1 \dots n = 39$, y las potencias predichas se calculan a partir de estas predicciones y utlizando la topología de la red. Distinguimos 3 subconjuntos del conjunto de nodos del grafo, agrupando los nodos según su tipo, PQ, PV, Slack. Tambien se aclara que MSE hace referencia a *Mean Squared Error* o error cuadrático medio.

$$\text{loss}_{V_{PV}} = \text{MSE}_{i \in PV}(V_{\text{truth}}, V_{\text{pred}}) \tag{5}$$

$$\text{loss}_{P_{PV}} = \text{MSE}_{i \in PV}(P_{\text{truth}}, P_{\text{pred}}) \tag{6}$$

$$\text{loss}_{PQ} = \text{MSE}_{i \in PQ}(P_{\text{truth}}, P_{\text{pred}}) + \text{MSE}_{i \in PQ}(Q_{\text{truth}}, Q_{\text{pred}}) \tag{7}$$

$$\text{loss}_{\text{Slack}} = \text{MSE}_{i \in \text{Slack}}\big((V_{\text{truth}}, \theta_{\text{truth}}), (V_{\text{pred}}, \theta_{\text{pred}})\big) \tag{8}$$

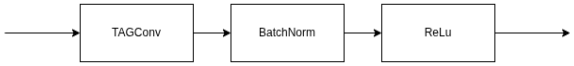

Figura 3: Capas del Modelo Convolucional

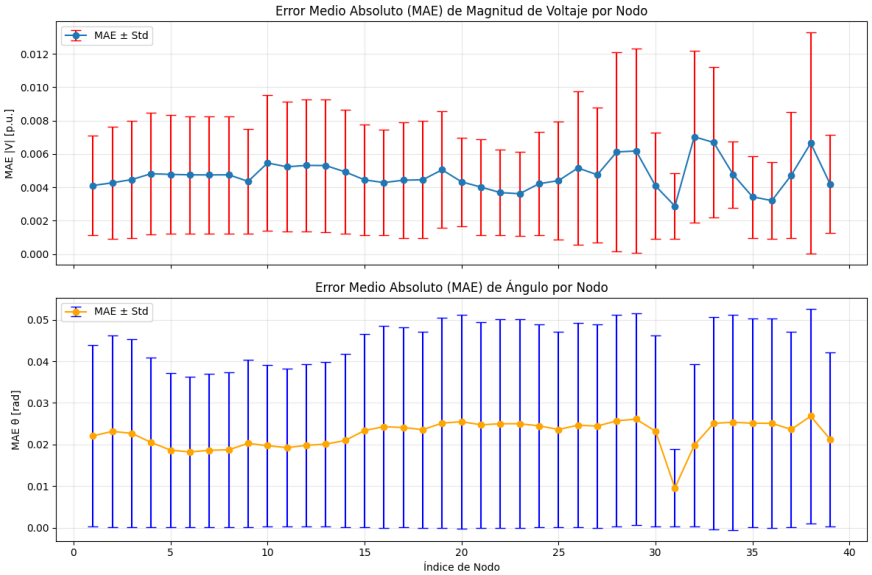

Figura 4: Performance en Validación del Modelo Convolucional

La Loss utilizada es la suma de todas estas, a la que posteriormente se le agregó un término de penalización para predicciones de voltaje negativas (físicamente incoherentes) ya que el modelo encontraba un atajo para minimizar la loss en el sector negativo del espacio de soluciones.

Modelos

En esta sección se detallan los modelos utilizados para los entrenamientos. Se distinguen entre modelos convolucionales y de mecanismos de atención *(attention)*.
Además se desarrolla el proceso de entrenamiento y los resultados de los experimentos realizados junto con comparaciones para visualizar el desempeño de los modelos entrenados sobre datos de validación.

Modelo Convolucional

El primer modelo que se probó en este trabajo es el modelo convolucional visto en el laboratorio del curso, compuesto por 3 capas de las que se observan en la figura 3, donde se fijó una cantidad de vecinos $k = 10$, dando como resultado un *Receptive Field* de 30, lo cual es más que suficiente para grafos como el de la figura 2. De todas formas, es importante asegurarse de que cada nodo obtenga información de todos los demás, pensando en la resolución del problema de flujo de carga, donde el valor de tensión a predecir de cada nodo depende de todos los demás nodos del grafo.
Se entrenó este modelo durante 150 épocas, con un optimizador Adam de *learning_rate* igual a 1×10^{-3} y un tamaño de batch de 512 muestras. Se reservó para validación un 10 % del total de los datos, obteniendo un total aproximado de 35000 datos de validación y 300000 para entrenamiento.
Al final del entrenamiento, el mejor valor alcanzado para la loss en validación fue de aproximadamente 1×10^{-3}.
Luego se evalúa el resultado del entrenamiento sobre el conjunto de validación en la figura 4, donde se grafica el error MAE y la desviación estandar para las predicciones del módulo y fase, promediando individualmente en cada nodo. Por otro lado, en la figura 5a se puede observar una comparación entre las predicciones del modelo y las etiquetas reales para un dato arbitrario del conjunto de validación, donde se observa una predicción muy buena. Por otro lado, en la figura 5b se observa un dato selec-

cionado del conjunto de entrenamiento donde la predicción ya no es tan satisfactoria, principalmente en cuanto al desfasaje. De todas formas, en promedio el rendimiento del modelo es muy satisfactorio.

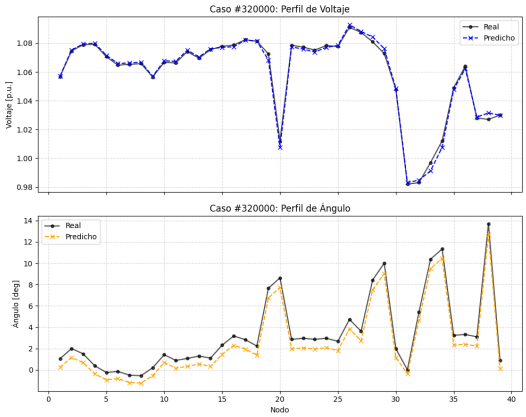

(a) Predicciones vs Ground Truth caso 320000

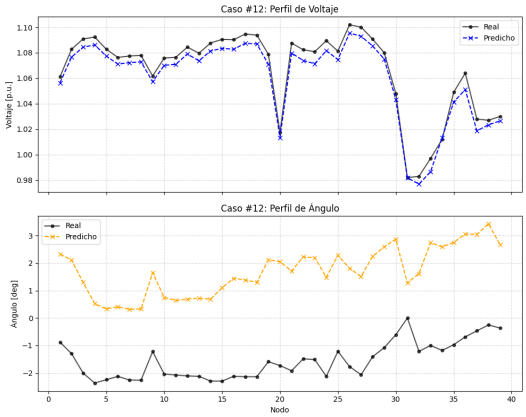

(b) Predicciones vs Ground Truth caso 12

Figura 5: Comparación entre dos imágenes

Desempeño del Modelo Convolucional con Contingencia

Una prueba importante de robustez para el modelo es evaluarlo sobre contingencias. Se denomina contingencia en el contexto del problema de flujo de carga al hecho de eliminar una línea (arista) de la red y observar como cambia el resultado del flujo manteniendo los mismos valores en las entradas. Este tipo de experimentos son muy comunes para planificación futura sobre la red eléctrica.
Para evaluar la contingencia, se eligió arbitrariamente eliminar la arista entre los nodos 2 y 3 (ver figura 2). Luego se volvieron a calcular nuevamente todas las salidas teniendo en cuenta este cambio en la red, y las entradas se mantuvieron iguales. No hubo que hacer adaptaciones del modelo ya que lo único que cambia es la matriz de adyacencia de los grafos de entrada. En la figura 6 se puede observar el desempeño promedio del modelo sobre 15000 datos seleccionados al azar dentro del dataset pero con la contingencia 2-3 aplicada. Es importante notar que se está evaluando sobre datos nuevos de test, ya que aunque las entradas de los datos sean las mismas, los grafos no lo son.
En la figura 6 se observa como el modelo pierde rendimiento general en algunos nodos específicos como el nodo 2, que es uno de los nodos que perdió una conexión. Tambien los nodos 18, 25 y 30, que están conectados a los nodos 2 y 3 que son justamente los que se desconectaron. Esto muestra que los nodos más afectados en rendimiento son aquellos directamente ligados a los nodos que se desconectaron, junto con éstos últimos. De todas formas, el resultado global promedio continúa siendo satisfactorio ya que el MAE promedio es relativamente bajo para todos los nodos.

Modelos con mecánismos de atención

En el problema de flujo de carga sobre redes eléctricas, la topología del sistema se considera conocida y, en general, fija, mientras que el escenario de operación varía según la demanda y la generación. Hasta ahora se han utilizado modelos basados en convoluciones sobre grafos, en los cuales cada nodo combina la información de sus vecinos siempre de la misma manera. Este enfoque aprovecha bien la estructura de la red eléctrica, pero asume que la influencia de los nodos vecinos no cambia entre distintos escenarios de operación.
En una red eléctrica real el estado del sistema puede variar significativamente según los niveles de demanda, generación o la ocurrencia de contingencias. En estas situaciones, algunos nodos vecinos pueden volverse más relevantes que otros para describir el comportamiento local del sistema. Los modelos con mecanismos de atención permiten aprender ponderaciones en la agregación de los vecinos, de modo que la contribución de cada nodo pueda ajustarse según el estado operativo considerado. Esto permite que la influencia relativa de los vecinos no sea fija, sino que se adapte a las condiciones de cada escenario. Con estas ideas en mente, se incorporan modelos con mecanismos de atención para permitir que la información proveniente de los nodos vecinos sea combinada de forma adaptativa según el estado

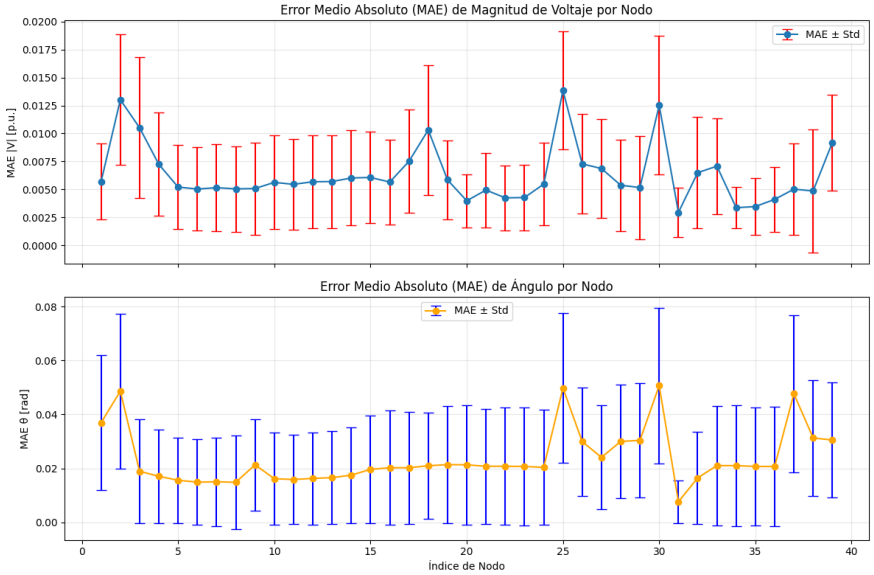

Figura 6: Modelo Convolucional Evaluado sobre la Contingencia 2-3

operativo del sistema. Para evaluar el impacto de incluír modelos con atención implementamos dos modelos con diferentes capas de atencion en cada uno.

GATConv

Graph Attention Networks (GAT) introducen mecanismos de atención al aprendizaje en grafos, permitiendo que cada nodo asigne diferentes pesos de importancia a sus vecinos durante el *message passing*. Para un nodo i con vecinos $\mathcal{N}(i)$, GATConv [6] calcula coeficientes de atención α_{ij} que determinan la importancia relativa del vecino j:

$$e_{ij} = \text{LeakyReLU}\left(\mathbf{a}^T[\mathbf{W}\mathbf{h}_i \| \mathbf{W}\mathbf{h}_j]\right) \tag{9}$$

Los coeficientes de atención son:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k\in\mathcal{N}(i)} \exp(e_{ik})} \tag{10}$$

donde $\mathbf{W}$ es una matriz de pesos compartida y $\mathbf{a}$ es el vector de atención aprendible. En particular en este trabajo usamos **GATv2Conv** [7] que provee mejoras sobre el modelo original **GATConv**.
Para el modelo se concatenaron 3 capas **GATv2Conv** con *LayerNormalization* y activación *ReLu*, como se puede ver en la figura 7:

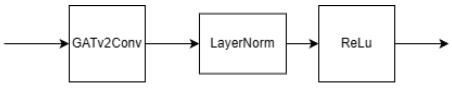

Figura 7: Capa GATv2Conv

TransformerConv

TransformerConv [8] adapta la arquitectura Transformer al dominio de grafos, a diferencia de GAT que usa concatenación, TransformerConv emplea un producto escalar

$$e_{ij} = \frac{(\mathbf{W}_Q\mathbf{h}_i)^T(\mathbf{W}_K\mathbf{h}_j)}{\sqrt{d}} \tag{11}$$

Donde $\mathbf{W_Q}$ y $\mathbf{W_K}$ son matrices de parametros a ajustar y d es la dimension de salida de la capa transformer. Los coeficientes de atención son:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})} \tag{12}$$

Al igual que con las capas **GATv2Conv** se planteó un modelo con 3 capas concatenadas como se ve en la figura 8:

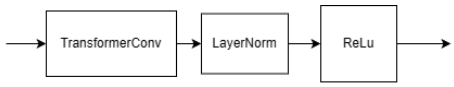

Figura 8: Capa TransformerConv

Se entrenaron ambos modelos durante 500 epocas usando el optimizador *Adam* con una tasa de aprendizaje de 1×10^{-4} fija y un tamaño de batch de 512 muestras. El objetivo de este entrenamiento es ver que método de atención nos da mejores resultados (y como se comparan con el modelo convolucional), comparando primero solo los resultados de la minimización de la función de costo compuesta en el conjunto de validación.

Modelo	**Mejor Validation Loss**
GATv2Conv	$6{,}1 \times 10^{-3}$
TransformerConv	$2{,}0 \times 10^{-3}$

Cuadro 1: Mejor valor de pérdida de validación alcanzado por los modelos con mecanismos de atención.

Al evaluar el MAE sobre las predicciones de $\mathbf{V}$ y θ sobre cada nodo nos alejamos mucho de valores aceptables al comparar contra el baseline.

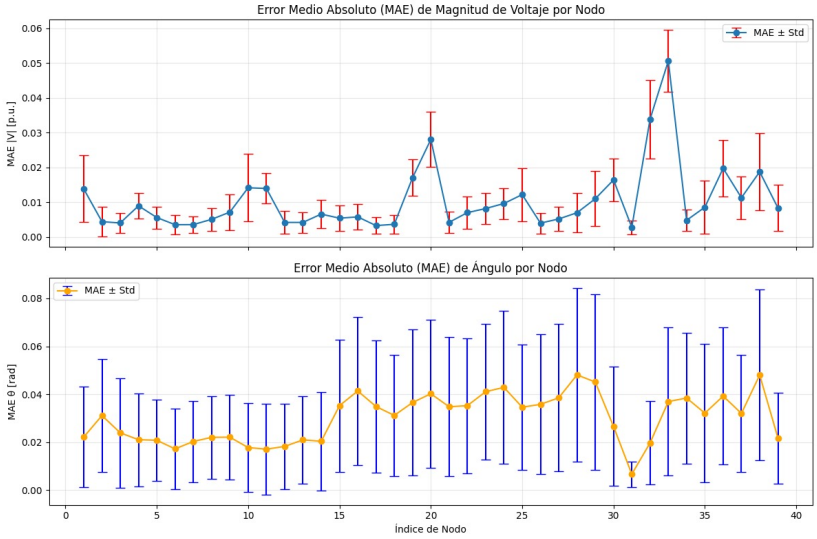

Figura 9: Evaluación del MAE de las predicciones para cada nodo sobre el conjunto de validación para el modelo con TransformerConv

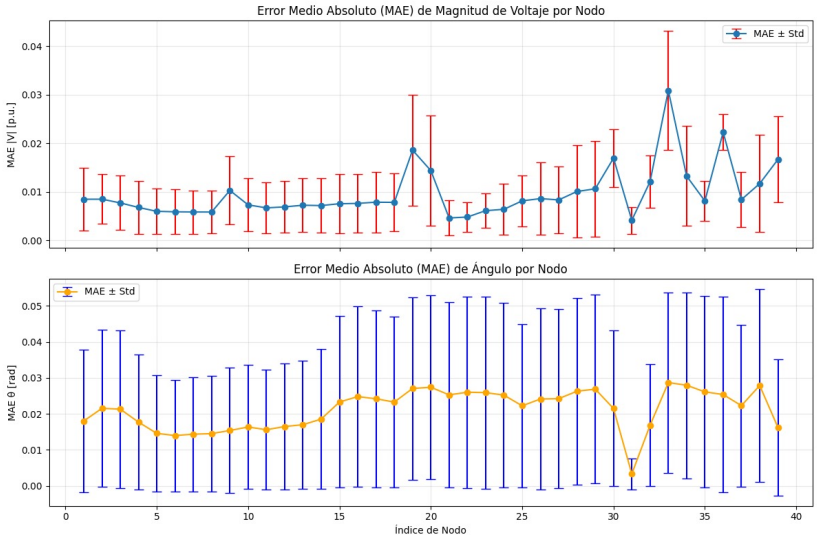

Figura 10: Evaluación del MAE de las predicciones para cada nodo sobre el conjunto de validación para el modelo con GATv2Conv

Estos modelos no alcanzan los resultados obtenidos mediante modelos convolucionales. Una de las razones principales de este comportamiento es el menor alcance efectivo del receptive field que presentan los modelos con mecanismos de atención cuando se utilizan arquitecturas de poca profundidad.
En los modelos con atención, la agregación de información se realiza únicamente sobre los nodos vecinos inmediatos en cada capa, por lo que el alcance de la información crece linealmente con la profundidad de la red. Con un número reducido de capas, estos modelos no logran incorporar la influencia de nodos alejados en la red.
Para el problema de flujo de cargas, el estado de un nodo depende del comportamiento global del sistema, incluyendo generadores y cargas que pueden encontrarse a varios saltos de distancia. Por ejemplo, con una profundiad de 3 capas, para la predicción sobre un nodo el modelo no incorpora información brindada por nodos que esten a mas de 3 saltos de distancia donde podríamos tener un generador inyectando potencia. Por esto último un modelo con atención poco profundo podría no incorporar información crítica para el problema que buscamos resolver.
Los modelos convolucionales multi-hop, como TAGConv, permiten incorporar esta información de largo alcance de manera directa mediante filtros de mayor orden, logrando capturar estas dependencias con pocas capas.
Por lo tanto, resulta razonable que los modelos con atención presenten un desempeño inferior en este problema, dado que la incorporación de la información global (o de nodos muy alejados) se ve limitada por la profundidad del modelo. Para poner a prueba esta hipótesis se corrieron algunos experimentos en los que se implementaron modelos de atención con arquitecturas profundas con el objetivo de igualar el *receptive field* de los modelos convolucionales. Para un modelo de 10 capas **GATv2Conv** obtenemos resultados considerablemente mejores, lo que apoya la idea de que para este problema resulta de gran importancia el alcance del modelo (figura 11).

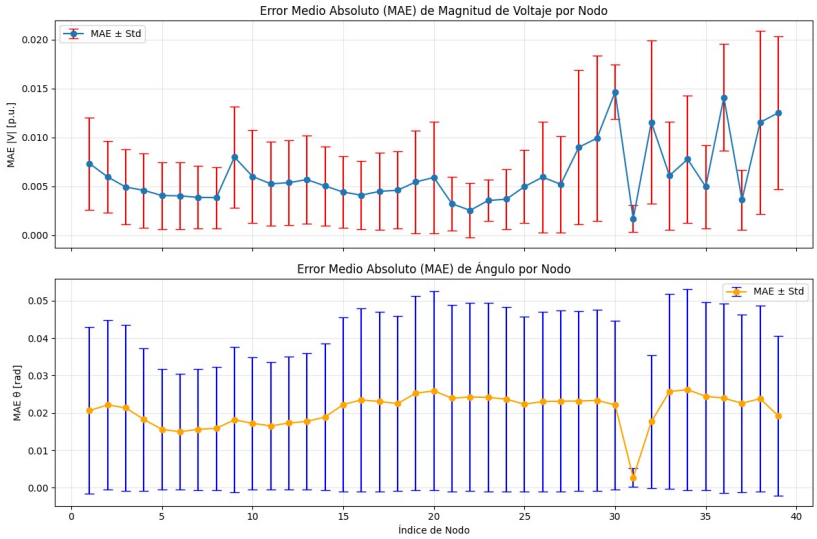

Figura 11: Evaluación del MAE para un modelo con 10 capas GATv2Conv

A su vez, cuando evaluamos el mismo modelo en contingencias (contingencias 2-3) obtenemos resultados esperados similares a los que obtuvimos con los modelos convolucionales, así como se observa en la figura 12. De todas formas, los valores MAE de error promedio muestran un rendimiento inferior comparado con el modelo convolucional (figura 6).

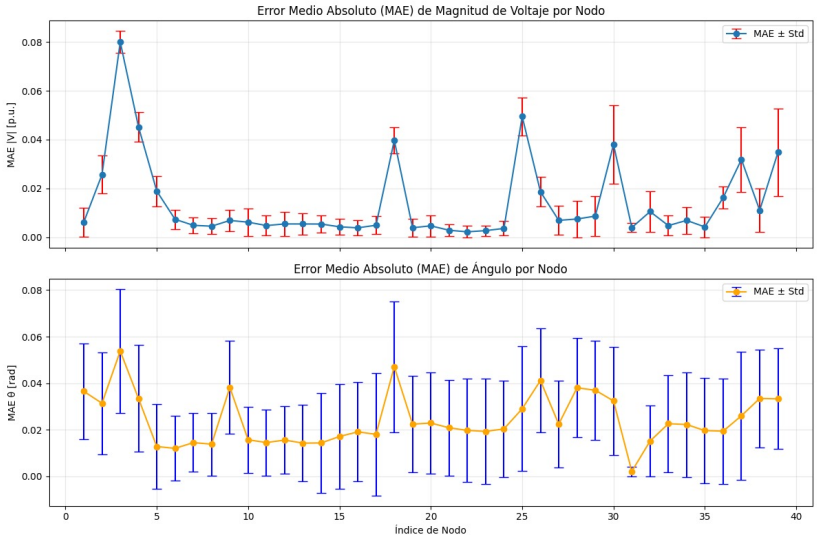

Figura 12: Evaluación del MAE para cada nodo en un escenario de contingencia

Conclusiones

Se probaron diversas arquitecturas para el problema de predicción del flujo de potencia en la red IEEE-39. En los experimentos realizados observamos que los modelos con atención requieren una mayor profundidad para alcanzar un desempeño comparable al de las arquitecturas convolucionales.
Este comportamiento nos da a entender que, para el problema de flujo de potencia, el tamaño del *receptive field* del modelo juega un rol central. Una mayor capacidad de propagación de la información a lo largo del grafo permite incorporar de forma más efectiva la influencia global de la red, lo cual resulta especialmente relevante dado que las inyecciones de potencia en los nodos generadores afectan, en distinta medida, los voltajes y ángulos de todos los nodos del sistema.

También es importante destacar que las redes de grafos logran capturar la escencia del problema físico detrás del flujo de carga, y reconocer patrones sobre la estructura de grafo subyacente de una red eléctrica de potencia.
La estructura del sistema permite realizar experimentos interesantes que no se realizaron para este proyecto particular. Sería interesante aprovechar la facilidad de generación de datos sintéticos y el enfoque no supervisado para crear datasets más variados que incluyan redes de distinto tamaño y con variadas contingencias incluídas.
Otro posible desafío es incorporar datos donde los valores de las impedancias de la red cambien a lo largo del dataset. Esto implicaría incorporar un modelo donde se tengan en cuenta además de las características de nodo, los atributos de las aristas, que en este estudio solo se utilizaron para el cálculo de la loss física y no como característica de entrada al modelo.
En este trabajo no se realizaron estudios para optimizar el entrenamiento del modelo, por lo que aún se puede mejorar mucho el desempeño del mismo sobre este conjunto de datos basado en la demanda de la red eléctrica de Uruguay.
Todo esto da pie a una línea de investigación novedosa que podría resultar en una herramienta útil para organismos como UTE a la hora de planificar la demanda de la red en el futuro, optimizando costos computacionales.

Bibliografía

[1] Repositorio git del Proyecto de Grado, *"GNN-Flow":* https://gitlab.fing.edu.uy/elias.courdin/gnn-flow

[2] Ignacio Boero, Santiago Díaz, Tomás Vázquez, *Despacho Óptimo de Reactiva con Aprendizaje Automático en la Red Eléctrica Uruguaya.*

[3]Balthazar Donon, Rémy Clément, Benjamin Donnot, Antoine Marot, Isabelle Guyon, Marc Schoenauer, *Neural Networks for Power Flow: Graph Neural Solver*, 2020.

[4] SIMSEE, *Sistema de Modelado de Sistemas Eléctricos de Energía.* https://simsee.org/

[5] Siemens AG, *PSS®E — Power System Simulator for Engineering.* https://www.siemens.com/global/en/products/energy/grid-software/planning/pss-software/pss-e.html

[6] *GATConv — Graph Attention Convolution.* Documentación oficial de PyTorch Geometric. https://pytorch-geometric.readthedocs.io/en/2.5.3/generated/torch_geometric.nn.conv.GATConv.html

[7] *GATv2Conv — Graph Attention Convolution v2.* Documentación oficial de PyTorch Geometric. https://pytorch-geometric.readthedocs.io/en/2.6.1/generated/torch_geometric.nn.conv.GATv2Conv.html

[8] *TransformerConv — Graph Transformer Convolution.* Documentación oficial de PyTorch Geometric. https://pytorch-geometric.readthedocs.io/en/2.4.0/generated/torch_geometric.nn.conv.TransformerConv.html

[9] Hadi Saadat, *Power System Analysis*, McGraw-Hill Education, 3rd Edition, 2011.